

«Создание модели прогнозирования заболеваемости населения»

Сорока Дмитрий

A large, dark blue, diagonal shape that starts from the bottom left and extends towards the top right, covering the lower half of the slide.

Постановка задачи.

В результате EDA и плотной работы с предлагаемыми данными, было принято решение рассматривать задачу в разрезе класса задач называемых “Временными рядами”.

В данных четко прослеживаются объекты (характеризуются признаками ПОЛ, БОЛЕЗНЬ, ГОРОД, ВОЗРАСТНАЯ КАТЕГОРИЯ) и динамика/история развития/изменения объектов по месяцам, начиная с января 2018 по март 2022.

Работа с данными

В процессе работы с данными оказалось удобным преобразовать исходный датафрейм, `train`, в вид удобный для восприятия/понимания и дальнейшей работы.

Датафрейм `train` был преобразован к классическому виду, для работы с `TimeSeries`, недостающие (`NaN`) значения представляем не как отсутствие наблюдений, а как число больных в этот месяц = 0.

Выбор модели

ML модель ARIMA отлично справляется с задачами прогнозирования на данных подобных тем, которыми мы располагаем.

В наших данных более 39 тысяч объектов и подбирать гиперпараметры ARIMA для каждого объекта будет слишком затратно по времени, попробуем кластеризовать наши данные и обучать модели покластерно.

Кластеризация

В процессе работы над задачей очень неплохо показала себя кластеризация временных рядов с TimeSeriesKMeans, но соизмеримый результат, в более простом исполнении, дала кластеризация наших объектов по признаку количества “пропущенных” значений или нулей в объекте.

Так и поступили - кластеризовали данные по признаку “полноты” или “заполненности”.

Score = 0.940999

Подбор гиперпараметров методом минимизации MSE позволил
покластерно обучить модель ARIMA и получить высокий результат.